



Analisis Pengaruh Transformasi Geometri terhadap Kinerja Klasifikasi Citra Menggunakan Convolutional Neural Network (CNN)

Dzakwan Muhammad Khairan Putra Purnama / 13524145^{1,2}

Program Studi Teknik Informatika - Sekolah Teknik Elektro dan Informatika

Institut Teknologi Bandung, Jl. Ganesha 10 Bandung 40132, Indonesia

13524145@std.stei.itb.ac.id, dzakwan.mkpp@gmail.com



Overview

01. Pendahuluan

02. Tujuan Penelitian

03. Landasan Teori

04. Metodologi

05. Hasil Eksperimen

06. Analisis dan
Diskusi

07. Kesimpulan

01. Pendahuluan

Memperkenalkan bidang dua dimensi pada anak usia dini penting dilakukan. Syaraf motorik anak masih halus dan butuh arahan dalam aktivitas menggambar bidang dua dimensi [1].

Pada sisi lain CNN sudah sangat populer dengan beragam keberhasilan mengenali bentuk pada sebuah gambar

Pada penelitian ini akan dikaji model klasifikasi potensial berbasis CNN dan Teknik transformasi geometri untuk menghasilkan model yang dapat mengidentifikasi gambar objek dua dimensi hasil coretan tangan anak usia dini

02. Tujuan Penelitian

+ Menganalisis dampak transformasi geometri terhadap kinerja CNN.

+ Membandingkan kinerja CNN:
Tanpa augmentasi data vs dengan augmentasi geometri

+ Menguji kemampuan generalisasi model pada data terbatas

03. Landasan Teori

- CNN efektif untuk klasifikasi citra, namun:
 - Translation-equivariant
 - Tidak rotation dan scale-invariant secara intrinsik
- Variasi gambar tangan direpresentasikan sebagai [2]:
 - Rotasi
 - Translasi
 - Scaling
- Augmentasi geometri diperkirakan membantu CNN mempelajari fitur yang invarian

04. Metodologi

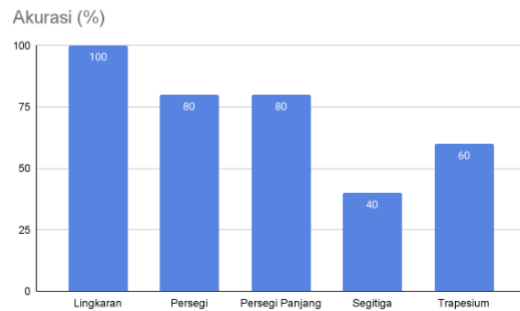
- Dataset:
 - 5 kelas bentuk geometri (@20 image)
 - Total 100 citra grayscale 56×56 piksel
- Pembagian data:
 - 75% data latih
 - 25% data uji
- Dua skenario eksperimen:
 - CNN tanpa augmentasi
 - CNN dengan augmentasi geometri

- Evaluasi menggunakan:
 - Confusion matrix,
 - Akurasi,
 - precision,
 - recall,
 - dan F1-score

05. Hasil Eksperimen

Tabel 1. Nilai evaluasi klasifikasi skenario 1

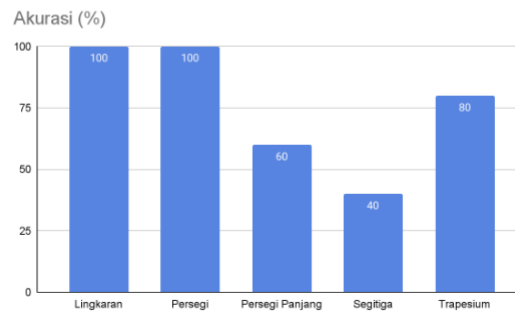
Kelas	Precision	Recall	F1-Score	Akurasi
Lingkaran	1.00	1.00	1.00	100%
Persegi	0.80	0.80	0.80	80%
Persegi Panjang	0.40	0.80	0.53	80%
Segitiga	1.00	0.40	0.57	40%
Trapesium	1.00	0.60	0.75	60%
Rata-rata (Macro)	0.84	0.72	0.73	72%



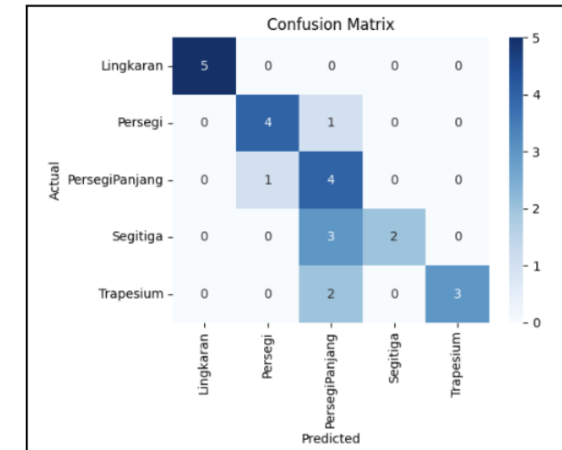
Gambar 5. Akurasi klasifikasi setiap kelas kategori (Skenario 1).

Tabel 2. Nilai evaluasi klasifikasi skenario 2

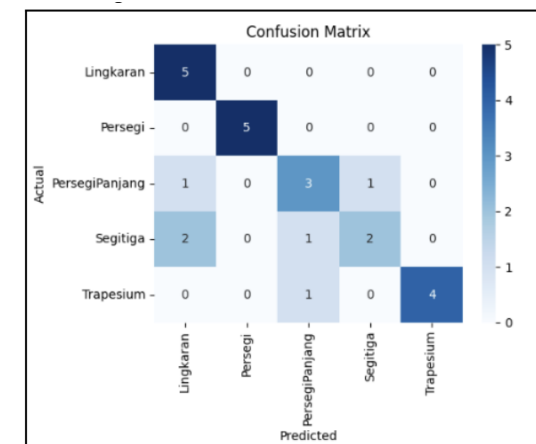
Kelas	Precision	Recall	F1-Score	Akurasi
Lingkaran	0.62	1.00	0.77	100%
Persegi	1.00	1.00	1.00	80%
Persegi Panjang	0.60	0.60	0.60	80%
Segitiga	0.67	0.40	0.50	40%
Trapesium	1.00	0.80	0.89	60%
Rata-rata (Macro)	0.78	0.76	0.75	72%



Gambar 8. Akurasi klasifikasi setiap kelas kategori (Skenario 2).



Gambar 6. Confusion Matrix Skenario 1



Gambar 9. Confusion Matrix Skenario 2

06. Analisis dan Diskusi

- Skenario tanpa augmentasi:
 - Akurasi: 72%
 - Performa tidak merata antar kelas
 - Segitiga memiliki recall terendah
- Skenario dengan augmentasi:
 - Akurasi meningkat menjadi 76%
 - Model lebih tahan terhadap rotasi dan pergeseran
 - Beberapa kelas masih perlu ditingkatkan akurasi

- Lingkaran mudah dikenali karena simetri rotasi
- Segitiga sensitif terhadap perubahan orientasi
- Augmentasi:
 - Mengurangi bias bentuk tertentu
 - Meningkatkan generalisasi model
 - Terdapat trade-off pada precision dan recall antar kelas

07. Kesimpulan

- Transformasi geometri meningkatkan ketahanan CNN
- Augmentasi data efektif untuk dataset berukuran kecil
- Konsep aljabar linier dan geometri penting dalam preprocessing
- Pendekatan ini potensial untuk aplikasi edukasi berbasis AI

Daftar pustaka

1. **Y. LeCun, L. Bottou, Y. Bengio, dan P. Haffner**, "Gradient-based learning applied to document recognition," Proceedings of the IEEE, vol. 86, no. 11, hal. 2278–2324, Nov. 1998. [Daring]. Tersedia: <https://ieeexplore.ieee.org/document/726791>. [Diakses: **22 Desember 2025**].
2. **A. Krizhevsky, I. Sutskever, dan G. E. Hinton**, "ImageNet classification with deep convolutional neural networks," dalam Advances in Neural Information Processing Systems (NIPS), vol. 25, 2012, hal. 1097–1105. [Daring]. Tersedia: <https://proceedings.neurips.cc/paper/2012/file/c399862d3b9d6b76c8436e924a68c45b-Paper.pdf>. [Diakses: **21 Desember 2025**].
3. **C. Shorten dan T. M. Khoshgoftaar**, "A survey on image data augmentation for deep learning," Journal of Big Data, vol. 6, no. 1, hal. 60, Jul. 2019. [Daring]. Tersedia: <https://journalofbigdata.springeropen.com/articles/10.1186/s40537-019-0197-0>. [Diakses: **24 Desember 2025**].
4. **I. Goodfellow, Y. Bengio, dan A. Courville**, Deep Learning. Cambridge, MA, USA: MIT Press, 2016. [Daring]. Tersedia: <https://www.deeplearningbook.org/> [Diakses: **22 Desember 2025**].
5. **P. Y. Simard, D. Steinkraus, dan J. C. Platt**, "Best practices for convolutional neural networks applied to visual document analysis," dalam Proceedings of the Seventh International Conference on Document Analysis and Recognition (ICDAR), 2003, hal. 958–963. [Daring]. Tersedia: <https://www.microsoft.com/en-us/research/publication/best-practices-for-convolutional-neural-networks-applied-to-visual-document-analysis/>. [Diakses: **23 Desember 2025**].
6. **R. C. Gonzalez dan R. E. Woods**, Digital Image Processing, edisi ke-4. New York, NY, USA: Pearson, 2018. [E-book]. Tersedia: <https://www.pearson.com/en-us/subject-catalog/p/digital-image-processing/P200000003254>. [Diakses: **24 Desember 2025**].